Laboratorio 6

Integrantes:

- Gino Jesús Daza Yalta
- Mikel Dan Bracamonte Toguchi

P1. (2 puntos) Escaneo Secuencial vs Índice GIN

1. Crear tabla:

2. Insertar datos aleatorios:

```
-- Inserta 10^7 registros aleatorios
INSERT INTO articles (content_lineal)
SELECT md5(random()::text)
FROM generate_series(1, 10000000) AS id;
```

- Copia a la columna indexadaUPDATE articles SET content gin = content lineal;
- 3. Crear índice GIN con trigramas:

```
CREATE INDEX idx_articles_trgm_gin ON articles USING GIN (content_gin gin_trgm_ops);
```

4. Crear subconjuntos más pequeños:

```
CREATE TABLE articles_1k AS SELECT * FROM articles LIMIT 1000; CREATE TABLE articles_10k AS SELECT * FROM articles LIMIT 10000; CREATE TABLE articles_100k AS SELECT * FROM articles LIMIT 100000; CREATE TABLE articles_1m AS SELECT * FROM articles LIMIT 1000000;
```

5. Crear índice en las copias:

```
CREATE INDEX idx_trgm_gin_1k ON articles_1k USING GIN (content_gin gin_trgm_ops); CREATE INDEX idx_trgm_gin_10k ON articles_10k USING GIN (content_gin gin_trgm_ops); CREATE INDEX idx_trgm_gin_100k ON articles_100k USING GIN (content_gin gin_trgm_ops);
```

CREATE INDEX idx_trgm_gin_1m ON articles_1m USING GIN (content_gin gin_trgm_ops);

6. Consultas sin y con índice:

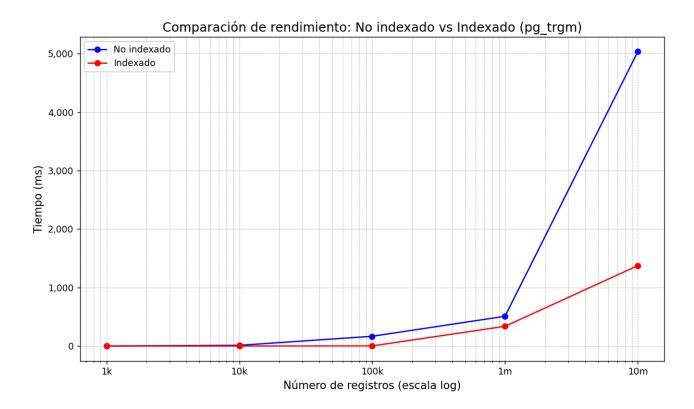
Sin indice:

EXPLAIN ANALYZE
SELECT COUNT(*) FROM articles_10k
WHERE content_lineal ILIKE '%abc%';

Con indice:

EXPLAIN ANALYZE
SELECT COUNT(*) FROM articles_10k
WHERE content_gin ILIKE '%abc%';

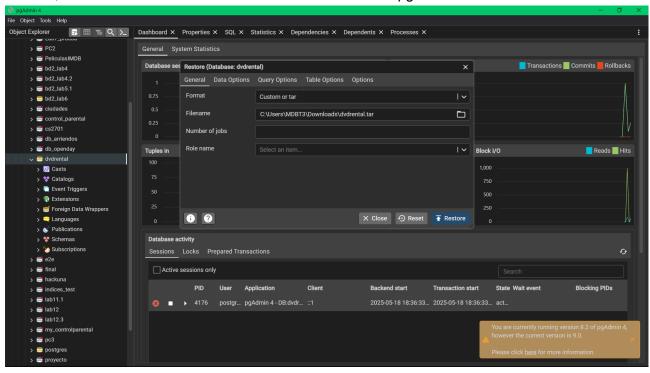
Cantidad de datos	Sin indice (ms)	Con indice (ms)
1k	1.23	0.094
10k	12.428	0.377
100k	166.779	2.298
1m	509.202	337.237
10m	5033.666	1375.336



El gráfico evidencia que el índice GIN basado en trigramas (pg_trgm) reduce significativamente los tiempos de búsqueda a medida que crece el volumen de datos. Mientras que sin índice el tiempo escala rápidamente (hasta 5 segundos en 10 millones de registros), el uso del índice permite mantener los tiempos bajo control, incluso en escalas grandes.

P2. (6 puntos) Búsqueda de Texto Completo en Películas

Primero, se restauró la base de datos con la herramienta de pgadmin.



Luego se crearon dos nuevas columnas donde se concatenaron el título y descripción en un vector de pesos. A una columna se le creó un índice GIN.

ALTER TABLE film ADD COLUMN vector_lineal tsvector; ALTER TABLE film ADD COLUMN vector_gin tsvector;

UPDATE film SET vector_lineal = to_tsvector('english', title || description); UPDATE film SET vector_gin = vector_lineal;

CREATE INDEX idx_film_vector ON film USING GIN(vector_gin); --usa keywords

Se hicieron consultas con y sin el índice mediante las siguientes queries y se midieron los tiempos:

EXPLAIN ANALYZE

SELECT title, description, vector_gin FROM film WHERE vector_gin @@

to_tsquery('english', 'Man & Woman')

EXPLAIN ANALYZE

SELECT title, description, vector_lineal FROM film WHERE vector_lineal @@ to_tsquery('english', 'Man & Woman')

Luego se duplicaron los registros mediante la siguiente instrucción, y se volvieron a medir los tiempos

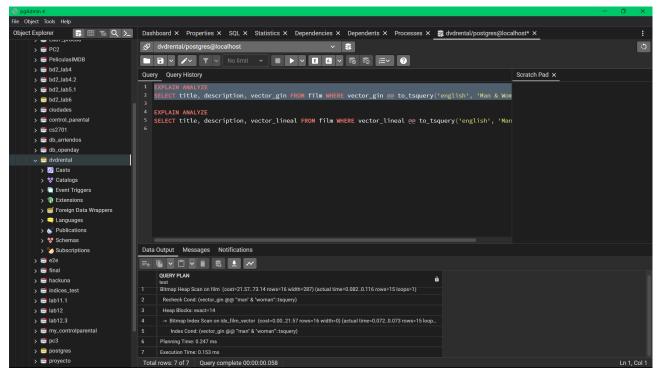
INSERT INTO film (title, description, language_id, vector_lineal, vector_gin) SELECT title, description, language id, vector lineal, vector gin FROM film

Los resultados fueron los siguientes:

Cantidad de registros	Tiempo sin índice (ms)	Tiempo con índice(ms)
1000	0.538	0.153
2000	0.762	0.157
4000	1.376	0.161
8000	2.643	0.223
16000	6.204	0.422

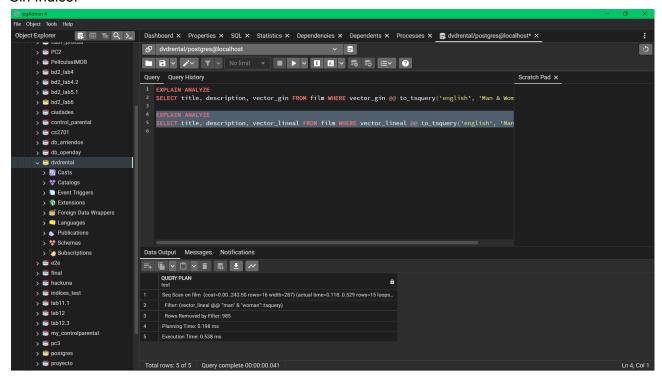
Por ejemplo para 1000 registros:

Con índice:



Acá se puede observar que sí se está usando el índice, ya que se hace un bitmap index scan usando el índice.

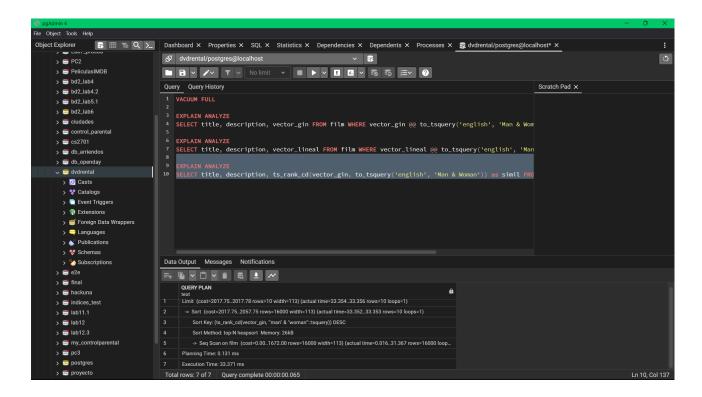
Sin índice:



Luego, se hizo la misma consulta (ahora hay 16000 datos), pero se rankearon por orden de similitud mediante la siguiente query:

SELECT title, description, ts_rank_cd(vector_gin, to_tsquery('english', 'Man & Woman')) as simil FROM film order by simil desc limit 10;

Resultado:



El tiempo de ejecución fue de 33.371ms, mucho más que el tiempo anterior sin rankear de 0.422ms. Además, se puede observar que el índice no se está usando, y se está haciendo un sequential scan.

P3. (6 puntos) Búsqueda de Texto Completo en Noticias

1. Crear la tabla articles e importar csv (se hizo con el import de pgadmin):

```
CREATE TABLE articles(
num INT PRIMARY KEY,
id INT,
title TEXT,
publication TEXT,
author TEXT,
date DATE,
year FLOAT,
month FLOAT,
url TEXT,
content TEXT
```

2. Generar un nuevo atributo indexado que combine el título y el contenido de cada noticia:

ALTER TABLE articles ADD COLUMN full text idx tsvector;

UPDATE articles

SET full_text_idx = to_tsvector('english', coalesce(title, ") || ' ' || coalesce(content, "));

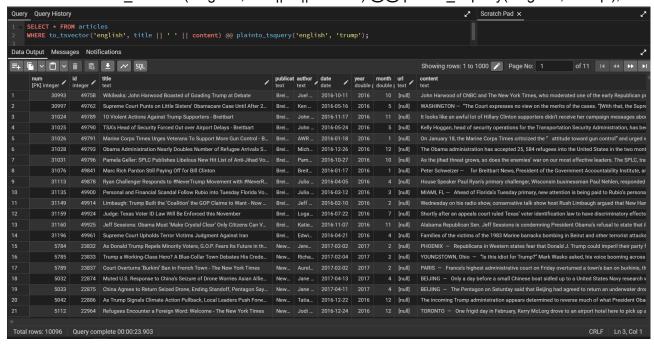
3. Crear un indice GIN sobre ese nuevo atributo:

CREATE INDEX gin_articles_idx ON articles USING GIN (full_text_idx);

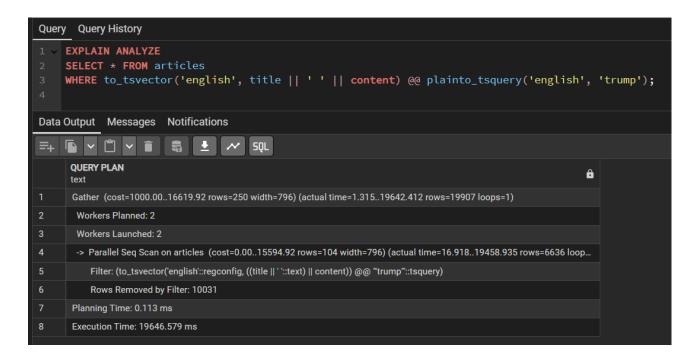
- 4. Ejecutar consultas de texto completo:
- 4.1 Resultados sin índice GIN:

EXPLAIN ANALYZE SELECT * FROM articles

WHERE to_tsvector('english', title || ' ' || content) @@ plainto_tsquery('english', 'trump');

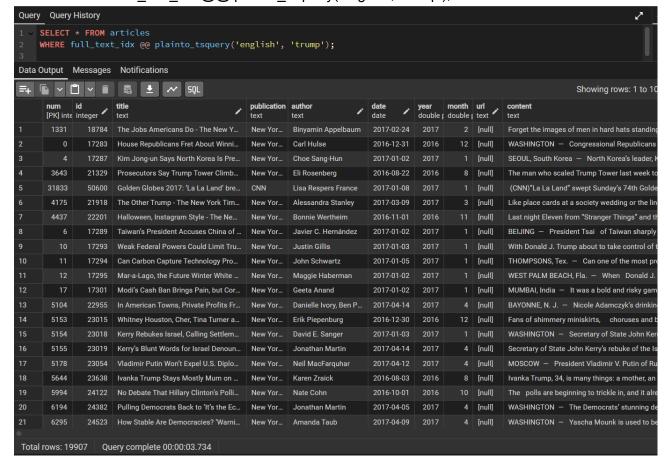


No usa indice:



4.2 Resultados con índice GIN:

SELECT * FROM articles
WHERE full_text_idx @@ plainto_tsquery('english', 'trump');



Prueba de que usa el índice:



5. Crear subconjuntos de datos aleatorios:

```
CREATE TABLE articles_1k AS SELECT * FROM articles ORDER BY random() LIMIT 1000; CREATE TABLE articles_10k AS SELECT * FROM articles ORDER BY random() LIMIT 10000; CREATE TABLE articles_25k AS SELECT * FROM articles ORDER BY random() LIMIT 25000; CREATE TABLE articles_50k AS SELECT * FROM articles ORDER BY random() LIMIT 50000;
```

- 6. Medir los tiempos de ejecución para diferentes tamaños de tabla:
- 6.1. Se hará la comparación con esta consulta:

Sin indice:

```
SELECT *, ts_rank(to_tsvector('english', title || ' ' || content), plainto_tsquery('english', 'climate change')) AS rank
FROM articles_50k
WHERE to_tsvector('english', title || ' ' || content) @@ plainto_tsquery('english', 'climate change')
ORDER BY rank DESC
LIMIT 10;
```

Con indice:

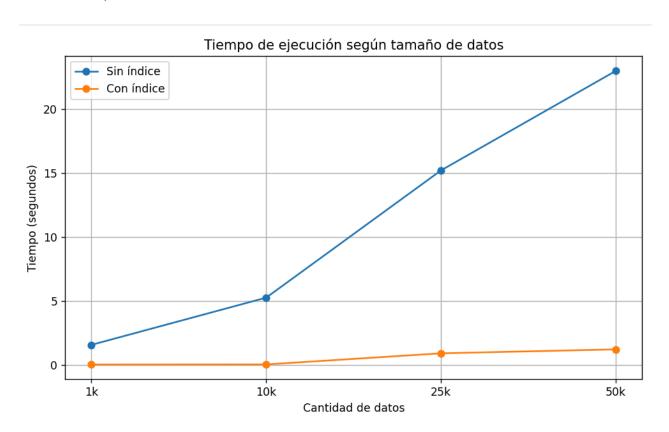
```
SELECT *, ts_rank(full_text_idx, plainto_tsquery('english', 'climate change')) AS rank FROM articles_50k WHERE full_text_idx @@ plainto_tsquery('english', 'climate change')
```

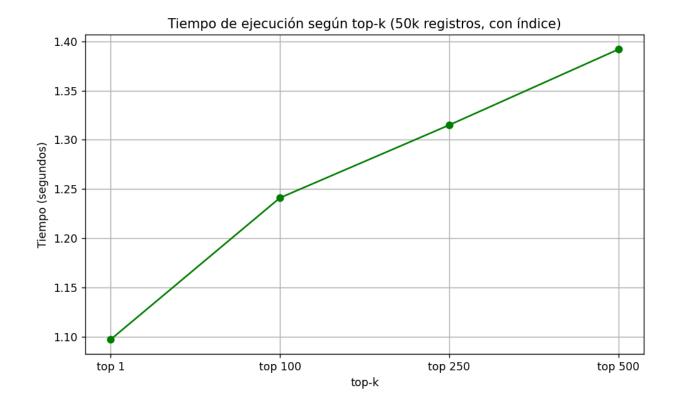
ORDER BY rank DESC LIMIT 10;

#Datos	Sin indice (seg)	Con indice (seg)
1k	1.553	0.0168
10k	5.250	0.0217
25k	15.213	0.892
50k	23.004	1.201

50k datos, con indice, top k:	Tiempo
top 1	1.097
top 100	1.241
top 250	1.315
top 500	1.392

Gráficos comparativos:





El primer gráfico muestra que el uso del índice GIN mejora significativamente el rendimiento a medida que crece el volumen de datos. El segundo gráfico demuestra que aumentar el valor de top-k tiene un impacto moderado en el tiempo de ejecución, aunque el índice sigue manteniendo un rendimiento eficiente.

P4. (6 puntos) Comparación de Índices GIN vs GIST en Noticias

Usando el mismo dataset de la pregunta anterior, se crearon dos tablas idénticas.

```
CREATE TABLE articles_gin(
    num INT PRIMARY KEY,
    id INT,
    title TEXT,
    publication TEXT,
    author TEXT,
    date DATE,
    year FLOAT,
    month FLOAT,
    url TEXT,
    content TEXT
);

CREATE TABLE articles_gist(
    num INT PRIMARY KEY,
    id INT,
```

```
title TEXT,
publication TEXT,
author TEXT,
date DATE,
year FLOAT,
month FLOAT,
url TEXT,
content TEXT
);
```

Se insertaron los datos del dataset usando la herramienta de pgadmin, y luego se crearon dos nuevas columnas donde estará el full_text.

```
ALTER TABLE articles_gin ADD COLUMN full_text_idx tsvector;

ALTER TABLE articles_gist ADD COLUMN full_text_idx tsvector;

UPDATE articles_gin

SET full_text_idx = to_tsvector('english', coalesce(title, ") || ' ' || coalesce(content, "));

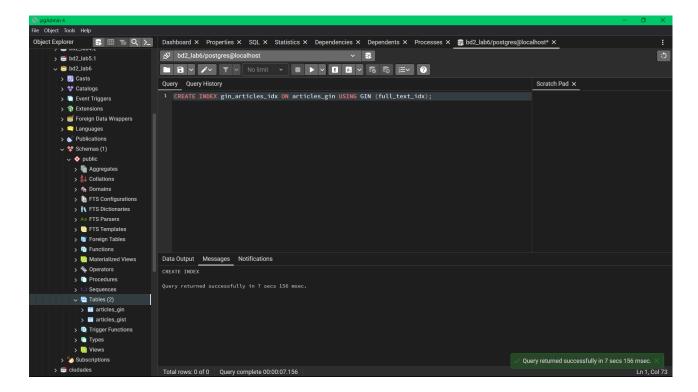
INSERT INTO articles_gist SELECT * FROM articles_gin;
```

Ahora tenemos dos tablas idénticas, una se usará para el índice gin y la otra para el índice gist.

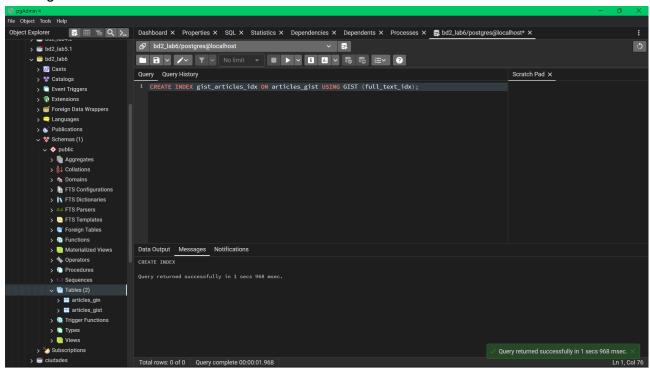
Primero, se crearon los índices respectivos usando las siguientes instrucciones y se tomó el tiempo de creación:

```
CREATE INDEX gin_articles_idx ON articles_gin USING GIN (full_text_idx); CREATE INDEX gist_articles_idx ON articles_gist USING GIST (full_text_idx);
```

Tiempo de creación: Índice gin:



Índice gist:



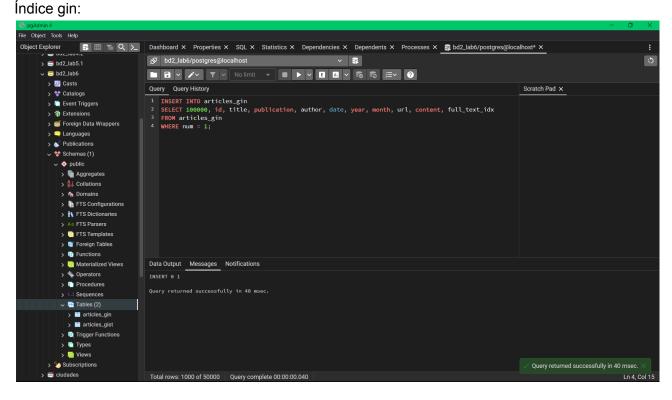
La creación del índice gin demoró 7.156 segundos, mientras que la creación del índice gist demoró 1.968 segundos. El índice gist se creó mucho más rápido que el gin.

Ahora compararemos el tiempo de inserción de un registro usando las siguientes instrucciones:

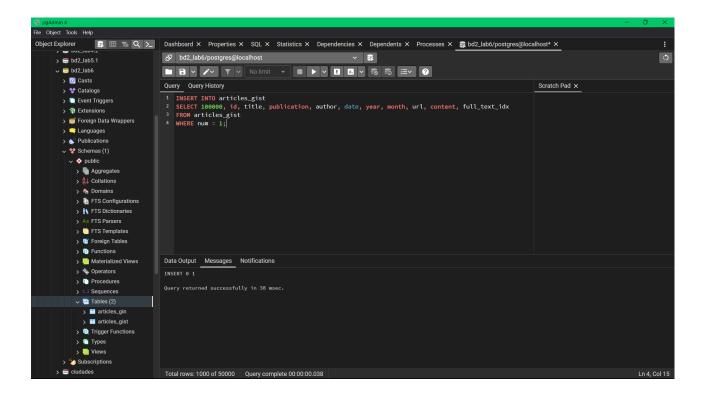
INSERT INTO articles_gin SELECT 100000, id, title, publication, author, date, year, month, url, content, full_text_idx FROM articles_gin WHERE num = 1;

INSERT INTO articles_gist SELECT 100000, id, title, publication, author, date, year, month, url, content, full_text_idx FROM articles_gist WHERE num = 1;

Tiempo de inserción:



Índice gist:



La inserción con el índice gin demoró 40ms, y con el índice gist demoró 38ms, prácticamente el mismo tiempo.

Ahora compararemos el tiempo de búsqueda usando las siguientes consultas:

EXPLAIN ANALYZE

SELECT * FROM articles_gin

WHERE full_text_idx @@ plainto_tsquery('english', 'trump');

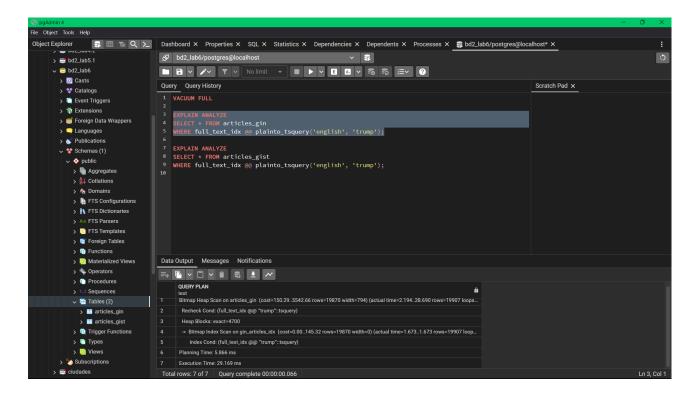
EXPLAIN ANALYZE

SELECT * FROM articles_gist

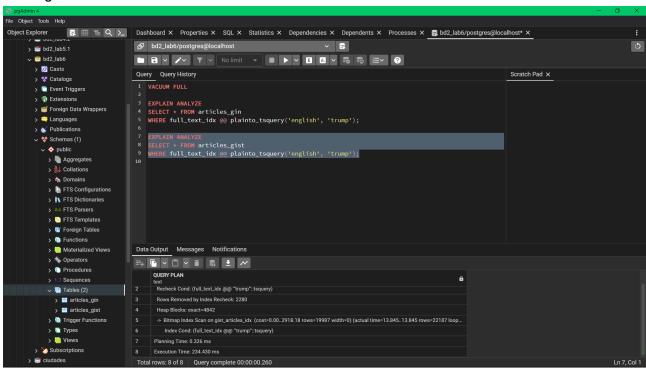
WHERE full_text_idx @@ plainto_tsquery('english', 'trump');

Se tuvo que deshabilitar el sequential scan para forzar el uso del índice.

Tiempo de búsqueda: Índice gin:



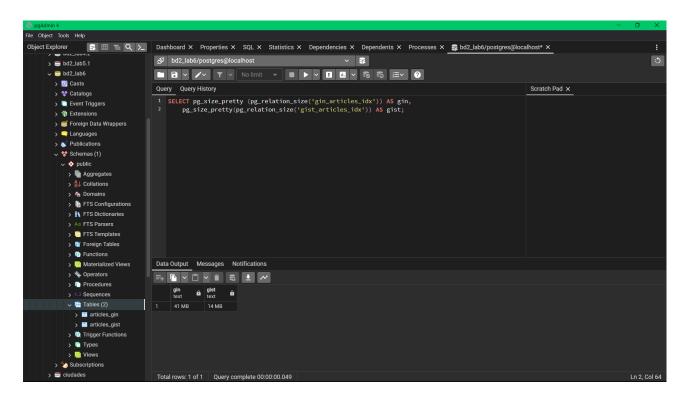
Índice gist:



La búsqueda con el índice gin demoró 29.169 ms, mientras que con el índice gist demoró 234.430 ms. Se puede ver cómo el índice gin logró una consulta mucho más rápida.

Ahora compararemos el tamaño en disco de ambos índices. Ejecutamos la siguiente consulta:

SELECT pg_size_pretty (pg_relation_size('gin_articles_idx')) AS gin, pg_size_pretty(pg_relation_size('gist_articles_idx')) AS gist;



El índice gin ocupa 41MB, y el índice gist ocupa 14MB. Con esto podemos ver que el índice gin pesa mucho más que el índice gist.

Resumiendo todos los resultados en una tabla, tenemos lo siguiente:

	GIN	GiST
Tiempo de creación (s)	7.156	1.968
Tiempo de inserción (ms)	40	38
Tiempo de búsqueda (ms)	29.169	234.430
Tamaño en disco (MB)	41	14

El tiempo de creación no significa mucho, ya que solo se toma en cuenta una única vez, al crear el índice. Igual cabe mencionar que el índice gin demoró mucho más tiempo en crearse. El tiempo de inserción es prácticamente idéntico en ambos índices. Sin embargo, el tiempo de búsqueda nos da a conocer una diferencia importante. El índice gist demoró aproximadamente 8 veces más en dar una respuesta, por lo que el gin es mucho más eficiente. A cambio de esta mejora en el tiempo de búsqueda, podemos ver cómo el índice gin ocupa mucho más espacio en disco, por lo que esa mejora en rapidez tiene un costo.

Para concluir, podemos decir que el índice gin ofrece un mejor rendimiento que el índice gist, a cambio de un aumento en el espacio que ocupa en disco.